

Aluno: Giovana Lins Cavalcanti
Matrícula: 22352925

Metodologia

Para alcançar o objetivo do trabalho, foram utilizados três Large Language Models (LLMs): DeepSeek V4, GLM 5.1 e LLama 4 Maverick. A metodologia foi dividida em duas etapas: (1) criação do conjunto de testes e (2) implementação do pipeline.

O conjunto de testes é composto por 20 mensagens com temas cotidianos, pertencentes a uma dessas categorias: pedido, cobrança, recusa, agradecimento, convite, esclarecimento, confirmação e adiamento. O tom utilizado varia entre formal, informal, cordial e direto, na espera de avaliar como o Verbalized Sampling (VS) afeta a adequação das respostas ao contexto.

Para comparar as respostas, as mensagens passam por um pipeline onde, primeiramente, são inseridas no prompt sendo testado. Em seguida, esse prompt é passado via chamada de API às LLMs, gerando uma resposta em formato JSON que é salva num arquivo. Cada arquivo JSON é composto de chaves representando a ordem da mensagem no conjunto de testes e valores compostos pelo texto da resposta e, no caso dos prompts utilizando VS, das probabilidades de cada resposta.

Em ambos prompts que utilizam VS, apelidados de “simples” e “agressivo” nesse experimento, foram pedidas 3 respostas com probabilidades distintas. O VS agressivo é caracterizado por pedir que a probabilidade das respostas dadas sejam iguais ou menores que 0,05 em relação à distribuição total, em oposição ao VS simples, o qual não restringe a probabilidade das respostas. Por fim, foram utilizadas oito métricas para avaliar as respostas dadas, sendo quatro métricas calculadas e quatro métricas avaliadas manualmente.

Resultados

É possível visualizar os resultados das métricas automáticas nas Tabela 1, 2, 3 e 4.

Modelo	Jaccard (Baseline)	Jaccard (VS simples)	Jaccard (VS agressivo)
Deepseek V4	0.0208	0.0169	0.0172
GLM 5.1	0.0754	0.0	0.0169
Llama 4 Maverick	0.0022	0.0	0.0212

Tabela 1: métrica Jaccard.

Modelo	Perplexity (Baseline)	Perplexity (VS simples)	Perplexity (VS agressivo)
Deepseek V4	113.0812	118.9263	143.2174
GLM 5.1	175.5284	72.2188	104.3937
Llama 4 Maverick	138.8230	115.1180	76.1502

Tabela 2: métrica Perplexity.

Modelo	Self-BLEU (Baseline)	Self-BLEU (VS simples)	Self-BLEU (VS agressivo)
Deepseek V4	0.4810	0.6923	0.6305
GLM 5.1	0.5172	0.6832	0.6741
Llama 4 Maverick	0.4089	0.7419	0.7194

Tabela 3: métrica Self-BLEU.

Modelo	Distinct-1 (Baseline)	Distinct-1 (VS simples)	Distinct-1 (VS agressivo)
Deepseek V4	0.0526	0.0196	0.0168
GLM 5.1	0.0451	0.0282	0.0199
Llama 4 Maverick	0.0673	0.0220	0.0272

Tabela 4: métrica Distinct-1.

Modelo	Distinct-2 (Baseline)	Distinct-2 (VS simples)	Distinct-2 (VS agressivo)
Deepseek V4	0.3436	0.1653	0.1571
GLM 5.1	0.3064	0.2118	0.1722
Llama 4 Maverick	0.3965	0.1690	0.2001

Tabela 5: métrica Distinct-2.

Observou-se que o uso de VS simples obteve melhores resultados nas métricas, com exceção das variações de Distinct-N, que indicou menor variedade léxica do que com o uso do prompt de baseline e do VS agressivo. Em contrapartida, ambos usos de prompts com VS demonstraram maior naturalidade nas respostas e menos respostas repetidas que o baseline, como verificado pelas métricas Perplexity e Self-BLEU, respectivamente. Curiosamente, as respostas vindas dos modelos GLM

5.1 e LLama 4 Maverick apresentaram nenhuma sobreposição lexical, medida pela métrica Jaccard, ao utilizar o prompt com VS simples.

Além do cálculo de métricas, foram avaliadas cada resposta dada pelas LLMs com base nas seguintes qualidades: utilidade, coerência, fidelidade à mensagem original e adequação ao tom pedido. Tais métricas são avaliadas de 1 a 5, sendo 1 a pior nota e 5 a melhor. A análise individual se encontra na Tabela 6, 7 e 8. Para facilitar a visualização, respostas do mesmo tipo de prompt que tiveram a mesma avaliação foram truncadas numa mesma linha.

Respostas	Utilidade	Coerência	Fidelidade	Adequação
Baseline 1–2, 4–9, 11–19	5	5	5	5
Baseline 3	5	5	4	4
Baseline 10	4	4	4	5
Baseline 20	2	3	2	5
VS simples 1.1, 1.3, 2.2, 3.1–6.1, 6.3–7.2, 8.1–14.3, 15.2–19.3	5	5	5	5
VS simples 1.2	4	4	5	5
VS simples 2.1	4	5	5	4
VS simples 2.3	4	5	5	5
VS simples 6.2	3	4	5	5
VS simples 7.3	1	2	1	5
VS simples 15.1	5	5	5	4
VS simples 20.1	1	1	4	3
VS simples 20.2	3	4	5	5
VS simples 20.3	2	4	4	2
VS agressivo 1.1–4.3, 5.2–7.2, 8.1–11.3, 12.2–14.2, 15.1–19.2	5	5	5	5
VS agressivo 5.1, 5.3, 19.3	5	5	5	3
VS agressivo 7.3	3	3	5	4

VS agressivo 12.1, 14.3	5	5	5	4
VS simples 20.1	2	4	4	3
VS simples 20.2	3	4	4	5
VS simples 20.3	1	1	1	2

Tabela 6: métricas manuais das respostas do Deepskeek V4.

Respostas	Utilidade	Coerência	Fidelidade	Adequação
Baseline 1–19	5	5	5	5
Baseline 20	1	1	1	5
VS simples 1.1–6.2, 7.1–7.2, 8.1–14.1, 14.3–19.3	5	5	5	5
VS simples 6.3	4	5	5	3
VS simples 7.3	1	5	5	1
VS simples 14.2	3	3	3	5
VS simples 20.1	1	2	3	5
VS simples 20.2, 20.3	3	5	5	4
VS agressivo 1.1–1.2, 11.1, 14.1, 14.3, 19.1–19.2	3	5	5	3
VS agressivo 1.3, 2.3, 4.3, 11.3–13.1	1	3	3	1
VS agressivo 2.1, 13.3	5	4	5	5
VS agressivo 2.2	2	5	5	5
VS agressivo 3.1–4.1, 5.2–6.1, 7.1–7.3, 9.2–9.3, 10.3, 11.2, 13.2, 15.1–16.2, 17.1–18.3, 19.3	5	5	5	5
VS agressivo 4.2	5	5	5	3
VS agressivo 5.1	4	5	5	5

VS agressivo 6.2, 6.3	1	2	4	3
VS agressivo 8.1–9.1, 10.1–10.2	1	2	2	5
VS agressivo 14.2	2	2	3	3
VS agressivo 16.3	4	4	5	5
VS agressivo 20.1–20.3	1	2	3	5

Tabela 7: métricas manuais das respostas do GLM 5.1.

Respostas	Utilidade	Coerência	Fidelidade	Adequação
Baseline 1–11, 13, 15–19	5	5	5	5
Baseline 12	4	4	4	4
Baseline 14, 20	1	3	1	5
VS simples 1.1–5.1, 6.1–7.2, 8.1–9.1, 10.1–11.2, 12.3, 13.1–15.2, 16.1–20.1	5	5	5	5
VS simples 5.2, 5.3	5	5	5	4
VS simples 7.3, 9.2–9.3, 12.3	1	3	1	5
VS simples 11.3	3	3	4	3
VS simples 12.2	3	3	4	5
VS simples 15.3	3	5	5	5
VS simples 20.2	3	4	3	5
VS simples 20.3	3	5	5	5
VS agressivo 1.1–5.2, 6.1, 7.1–9.1, 10.1–10.2, 11.1–11.2, 12.1–12.2, 13.1, 13.3–14.2,	5	5	5	5

15.1–19.2				
VS agressivo 5.3, 13.2	5	5	5	4
VS agressivo 6.2–6.3, 11.3	4	5	5	3
VS agressivo 9.2–9.3, 14.3, 19.3	2	3	4	5
VS agressivo 10.3	2	3	2	5
VS agressivo 12.3	5	5	5	3
VS simples 20.1	4	5	5	5
VS simples 20.2–20.3	3	4	3	5

Tabela 8: métricas manuais das respostas do LLama 4 Maverick.

Em geral, as respostas geradas via VS simples, sem configurações agressivas de diversidade, obtiveram notas melhores do que as outras, gerando múltiplas respostas úteis que se adequam ao contexto. Notavelmente, nenhum dos modelos respondeu satisfatoriamente a vigésima mensagem (“Pessoal, a prova ficará para amanhã”) utilizando o prompt básico, respondendo como se estivessem falando com outros alunos ao invés de um professor, mas os prompts com VS permitiram que as LLMs gerassem respostas com melhor coerência e fidelidade à mensagem original. Isso sugere que o uso de VS é útil para responder entradas com aposto ambíguo.

Também observou-se que, nas respostas geradas com VS, mensagens com vocabulário informal obtiveram respostas com vocabulário equiparável, enquanto algumas mensagens formais obtiveram respostas com tom menos formal ou até rudes no contexto inserido. Mensagens rudes foram mais comuns ao utilizar o VS com configuração agressiva de diversidade, o que é esperado considerando a probabilidade baixa.